


2.1. Линеен дискриминантен анализ. o пак да се види с конспект

Тази статистическа процедура се използва, като се извършва от "прогнозиране" стойностите на групираща променлива. Точката това се нарича класификационен разпознаване на образи. Като нашата чифарка е нееднородна. Т.е. обстои се от няколко групиращи наблюдения с различни вероятностни характеристики. Изпита ти е да научиш от тази чифарка, по зададени параметри на дадено наблюдение, да определиш принадлежността му към класа, от който произлиза.

В линейния дискриминантен анализ се използват линейни дискриминантни функции от предикторите. За всеки клас има по една такава функция. Правилното за класификация е: Наблюдението се класифицира към класа с максимална дискриминантна $F-A$.

Областта от стойностите на предикторите, при попадане в която наблюдението се класифицира към даден клас е изключително многобройно. Тя се нарича класификационна област на класа. При два предиктора и четири класа класификационните множества биха могли да изглеждат така



Линейният дискриминантен анализ предполага, че разпределенията на количествените променливи (предикторите) вътре в класовете са кореланти и се различават само по средните си стойности. Това правдоподобно правим да отидем до решаване правилно. Тя може да се използва и при случаите (по групиращата) чифарка

но познати на пръв клас е недопустима.

Когато броят на количествените променливи е по-голям се отбират за предиктори само тези променливи, които носят важна за разглежданата информация. Това означава статистиката на Механобие. Тя ~~не~~ ^{позволява} да се провери хипотеза за съвпадение на груповите средни на предикторите като цяло. Вместо критичната област за статистиката се използва вероятността отговарящата разпределението с величината да не надхвърля стойността на статистиката. Тази вероятност расте докато променливите допринасят за по-добро разпределение на класовете и групите да намаляват, когато предикторите станат твърде много. Добро разделение може да се очаква, когато хипотезата им хвърля с ~~добро~~ висока вероятност.

Когато изберем най-добрите променливи за предиктор, ще означават, че ~~те~~ ^{те} се са построени класификационните функции. Основна цел на дискриминантния анализ е да се научи за приписване на едно ново наблюдение към даден клас. За това наблюдение може да възникне априорна информация за неговата възможна принадлежност към класовете. Такава и-я е ~~то~~ приемно да се формулира в термини на априорни вероятности ~~на класовете да се приемат за равни~~, които са необходими за определяне на оптимални класификационни правила.

Ако такава информация не съществува, априорните вероятности на класовете се приемат за равни. Когато извадката е случайна и равномерно разпределена и избира по случай начин, ние ~~та~~ да се приемат за пропорционални на обема на класовете в обучаващата извадка. Изборът на априорни вероятности фиксира оптимални дискретни функции и класификационни правила.

Не е удобно за π голео наблюдение да се въвеждат априорни вероятности. (~~Въвеждането е с голям значи-
телен изчислителен труд~~ Въвежен начин за
здобиването на това кудобство е представянето
на класове с помоща на икотоуиращи
променливи.

Бейсов подход.

Иска се извенти вероятности $\{p(g)\}$, груповите
средни $\{m(g)\}$ и вътрешно груповата ковариация
на матрица

$C(g) = C \quad g \in G (g = 1, 2, \dots, G)$ тогава по

формулата на Бейс, апостериорната вероятност
за класификация в клас g на наблюдението (x, \cdot)
ще бъде

$$q(g) = p(g) \cdot f(x, m(g), C)$$

Тук f е плътността на нормалното разпределение
све средна стойност $m(g)$ и ковариационна
матрица C , а c е нормираща константа
такава, че $\sum q(g) = 1$

Класификационни правила

Власко принципа за максимално правдоподобие,
класифицира се по правилото

$$\hat{g} = \max_{h: q(h)}$$

Класификационните правила могат да бъдат
записани във вида:

$$p(\hat{g}) \cdot f(x, m(\hat{g}), C) \geq p(h) \cdot f(x, m(h), C)$$

$$(h = 1, 2, \dots, G)$$

След транспонирване и ограничаване получаване:

$$b(\hat{g})'x + a(\hat{g}) \geq b(h)'x + a(h), (h=1,2,\dots,G)$$

Векторът $b(g)$ и числото $a(g)$ се получават по формулите:

$$b(h) = m(h)' C^{-1}, \quad a(h) = \log p(h) - m(h)' C^{-1} m(h)$$

Априорни вероятности. Можем

За априорните вероятности $\{p(g)\}$ може да използваме ней-губрите или оценки $\{m(g)/N\}$ при случаите на извадка или ^{група} априорна информация за оценката на $\{m(g)\}$ и с е използват вътрешно-груповите средни обединената извадка вътрешно-групово ковариации.

Когато групирани променливи са повече от едно по-на класове в нараства вероятността се появява на празни клетки ($m(g) = 0$) при случаите извадка с ограничен обем рязко се увеличава. Затруднява се и оценката за $\{m(g)\}$ в такива случаи се препоръчва използването на оценки по извадки или или модел като е направен съответните проверки с методите на дискриминационен анализ. Съответно ще се променят и оценката за C .

Същият дискриминационен анализ,

и тук е възприета концепцията за изборно подходящ набор от количествени променливи, с които да построим модела. Те се строят аналогично на регресиите, но рол на сумите от квадратите изразят

— вътрешно-груповата ковариационна матрица — между-груповата ковариационна матрица.

Како в едномерни случаи, така и в многомерни е вярно следното равенство:

$$\sum_i \sum_j (x_{ij} - \bar{x})(x_{ij} - \bar{x})' =$$

$$= \sum_i \sum_j (x_{ij} - \bar{x}_i)(x_{ij} - \bar{x}_i)' + \sum_i n_i (\bar{x}_i - \bar{x})(\bar{x}_i - \bar{x})'$$

$$SS = SS_{in} + SS_{mod}$$

Матрицата SS_{in} се тълкува като "сума от квадрати отоваряваща разсейването на данните около техните локални средни и с нея по-мощ се строи оценка за вътрешно-груповата ковариационна матрица

$$\hat{C} = \frac{1}{N - G + 1} SS_{in}$$

Матрицата SS_{mod} се тълкува като "сума от квадрати отоваряваща на разсейването на груповите средни и с нея по-мощ се строи оценка за между-груповата ковариационна матрица B_{mg} :"

$$C_{mg} = \frac{1}{G - 1} SS_{mg}$$

Согласно Фишер един дискриминационен анализ издобрее по-добър колкото е по-малко в зависимост на двете джъвери нати:

$$\lambda = \frac{|SS_{in}|}{|SS|} \quad \text{наричано критерий на Уилкс.}$$

При преминаване от дадена размерност k към размерност $k+1$ има извлечения:

$$\lambda = \frac{\lambda_{k+1}}{\lambda_k}$$

Ако новата променлива не ~~е~~ свързана близо до
разпределението статистиката

$$F = \left(\frac{n-m}{k} \right) \left(\frac{1-\lambda}{\lambda} \right) \text{ има разпределение на}$$

Фишер.